

Оптимизация приложений моделей глубинного обучения для задач геномики к предметной области вторичных структур в стволовых клетках

Нестеренко Алиса Вадимовна, БПМИ215

Научный руководитель: Боровский Андрей Олегович

ВШЭ ФКН, Прикладная математика и информатика


2025

- Помимо канонической В-формы, существует ряд других вторичных (пространственных) структур, таких как Z-ДНК и G-квадруплексы
- Вторичные структуры ДНК играют значительную роль в регуляторных функциях и коррелируют с рядом заболеваний (рак, болезнь Альцгеймера, диабет)
- Важная задача — предсказывать наличие или отсутствие определённой вторичной структуры на участке ДНК

Введение: Z-ДНК и G-квадруплексы


Z-ДНК:

- Спираль ДНК, закрученная в левую сторону
- Связана с раком, болезнью Альцгеймера
- Точные функции до конца не изучены
- Частота: 0.3-1% генома



G-квадруплексы (G4):

- Последовательности из 4 цепей, обогащённые гуанином
- Связаны с рядом генетических заболеваний
- Участвуют в регуляции, репарации ДНК и др.
- Частота: 1-2% генома



- Существующие ML-модели:
 - Полагаются только на последовательность нуклеотидов ДНК (G-квадруплексы)
 - Предсказания на всём геноме (нет спецификации по типу клеток/тканей)
 - Низкая F1-мера и, как следствие, аналитическая способность
- Кроме того, интересно выявление ключевых признаков, влияющих на предсказания модели — может помочь в дальнейшем для биологической интерпретации

- **Основная цель:** Повышение точности предсказания вторичных структур ДНК в плюрипотентных стволовых клетках с использованием глубинного обучения и интерпретация полученных результатов с помощью xAI-методов.
- **Задачи:**
 - Адаптация CNN-модели для анализа стволовых клеток (вместо всего генома)
 - Интеграция омиксных данных (гистоновые метки, транскрипторные факторы и т.д.)
 - Оптимизация архитектуры модели
 - Интерпретация значимых омиксных признаков с помощью xAI-методов и исследование релевантной биологической литературы
 - Сравнение значимых омиксных признаков на стволовых клетках со всем геномом (для Z-ДНК)


Устройство датасетов

- Человеческий референсный геном hg38, омиксные данные (ChIP-Atlas), Z-ДНК/G4 целевые переменные (Kouzine/EndoQuad датасеты)
- Омиксные данные: гистоновые метки, транскрипторные факторы, РНК-полимераза и др.

Feature	1	2	3	4	5	6	7	8	9	10
A	1	0	0	0	1	0	0	0	1	0
G	0	1	0	0	0	1	0	1	0	1
C	0	0	1	0	0	0	1	0	0	0
T	0	0	0	1	0	0	0	0	0	0
ATAC-seq	0.91	1.00	0.55	0.77	0.22	0.48	0.18	0.88	0.96	0.54
DNase-seq	0.87	0.96	0.55	0.77	0.16	0.47	0.13	0.91	1.00	0.51
H3K4me3	0.83	0.41	0.09	0.08	1.00	0.68	0.02	0.34	0.88	0.36
H3K27ac	0.93	0.44	0.33	0.75	0.08	0.31	0.05	0.84	1.00	0.47
H3K4me1	0.54	0.94	1.00	0.46	0.17	0.96	0.43	0.13	0.60	0.85
H3K9me3	0.07	0.13	0.04	0.41	0.09	0.16	1.00	0.45	0.03	0.95
H3K27me3	0.11	0.07	0.09	0.06	0.42	0.37	1.00	0.13	0.07	0.88

Начальная архитектура модели

- Свёрточная модель с 12 слоями + 2 линейных слоя в конце
- Выбираем интервалы ДНК для обучения/валидации в соотношении 1:3 (pos:neg)
- Начальная длина интервала 100
- Метрики: F1-мера (основная), ROC-AUC



Эксперименты: обе вторичные структуры


- Тестирование 5 типов кодирования омиксных данные: масштабирование на 1000, масштабирование на общий максимум, масштабирование на максимум каждого признака, стандартное масштабирование каждого признака, бинаризация. Лучшим оказалось масштабирование на общий максимум

Эксперименты: архитектура для G4

- Автоматический подбор гиперпараметров с помощью Optuna для подбора начальной архитектуры (+2.4% F1)
- SELU активация + удаление dilations (ухудшение F1)
- Добавление шедулера ReduceLROnPlateau (+0.6% F1)
- Residual connections (+1.1% F1)
- Добавление dropout после свёрточных слоёв (нет улучшений)
- Уменьшение числа каналов (F1 упала на 1%, но модель стала сильно быстрее учиться, что помогло с дальнейшими экспериментами)
- Подбор длины интервала: оптимум 50

Итоги: улучшение F1-меры с бейзлайна 67.86% до 73.25%

Финальная архитектура модели для G4



Фреймворк интерпретации

- Ансамбль методов xAI:
 - Integrated Gradients
 - InputXGradient
 - Deconvolution
 - Guided Backpropagation
- Процедура анализа:
 - Усреднение только по true positive примерам для каждого признака (true positive могут фильтроваться как до, так и после подачи в метод интерпретации — prefiltering и postfiltering)
 - Для каждого признака считается среднее абсолютное отклонение
 - Различные комбинации методов интерпретации, исключение шумных
- Валидация:
 - Обучение на топ-N признаков для каждой вторичной структуры (оптимум: 50 для Z-DNA, 30 для G4)
 - Сравнение с существующими биологическими исследованиями

Оптимизация предсказаний:

- F1-мера: 89.96% (на всём геноме 88.15%).
- Ограничение на стволовые клетки, масштабирование на общий максимум, топ-50 важнейших омиксных признаков

Важнейшие омиксные признаки:

- H3K4me3, BRCA1, RNA Polymerase II, ZMAT4, H2A.Z, KDM2A, EPOP, ISL1, CHD6, H4K20me1
- Биологическая релевантность: H3K4me3 напрямую связана с формированием Z-ДНК, KDM2A регулирует формирование H3K4me3

Сравнение с общим случаем (всем геномом):

- Признаки H3K4me3, RNA Polymerase II, H3K27me3, H2A.Z имеют большое значение в обоих случаях
- Однако, много признаков в топах отличаются

Оптимизация предсказаний:

- F1-мера: 76.77% (против бейзлайна 67.86%)
- Ключевые изменения: residual connections, длина интервала 50, масштабирование на общий максимум, топ-30 важнейших омиксных признаков

Интерпретация:

- Важнейшие омиксные признаки: TP53BP1, BCOR, KDM1A, H3K4me3, H3K27ac, ATAC-seq, DNase-seq
- Биологическая релевантность: много G4 формируется в тех же регионах, где присутствуют активные промотеры, а также доступность хроматина — H3K4me3, H3K27ac и ATAC-seq, DNase-seq соответственно

Направления будущей работы

- Интерпретация k-меров во вторичных последовательностях
- Эксперименты с другими архитектурами
- Эксперименты с другими типами клеток/тканей
- Планируется публикация статьи в научном журнале уровня Q1

GitHub: https://github.com/cutehater/ZDNA__G4__Research